Ommatidia: 理解状態に基づく複眼型探索の設計と評価計画

状態: 論文下書き（提案・プロトコル設計段階）。実験未実施（Pending）。実証結果は未取得で、結果を待っている。

- **著者**: Ryoko Sakakibara（Independent Researcher）
- **ORCID**: 0009-0009-9544-6315

- **本文ライセンス**: CC BY 4.0

- **DOI**: 未付与。Zenodo への登録時に付与される。
- **著者情報の照合先**: Zenodo record 22925518

要旨

大規模言語モデル（LLM）を用いた調査エージェントが直面する最も重大な落とし穴の一つは、不完全な前提や隠れた反例に気付かぬまま、滑らかに誤った確信へと至ってしまう点にある。人間の一流の調査者が仮説の反証条件を執拗に洗うように、エージェントはいかにして自らの盲点を自律的に検証できるのか。本研究では、昆虫の複眼に着想を得た調査アーキテクチャ「Ommatidia（オマティディア）」の設計を提案する。本手法の中核は、思考をモデル内部のブラックボックスな文脈に閉じ込めるのではなく、目的・主張・仮説・取得済み証拠・未確認事項・検査履歴を外部の構造化台帳として明示管理する「理解状態（Understanding State）」にある。システムはこの理解状態から未確認事項を解き明かす具体的な「探索役（Investigators）」を動的に編成し、同一引用の重複に惑わされず、出所・時期・対象のズレや未解決の矛盾を直視しながら証拠を照合する。そして、呼出し回数・ツール数・文字数・トークン数・時間からなる厳格な複合予算の枠内で停止を自律判定する。

本稿では、代表的先行アプローチ（Self-RAG、Adaptive-RAG、STORM、Reflexion）の公式仕様との対比を通じて本アーキテクチャの機会構造を解剖するとともに、事前登録型（Preregistered）の比較実験計画（PROTOCOL）を詳述する。実験は、通常探索、一般的再点検、固定観点、単独適応探索、Ommatidiaの5条件にわたり、開発24ケース＋評価24ケースの計240試行、1試行あたり最大8回・全体で最大1,920回のモデル呼出し上限で設計される。現時点で実モデルによる試行数は0件、費用・トークン消費量は未測定であり、4論文以外の網羅的調査を行っていないため新規性や優位性の主張は行わない。すべての仮説の審判は、厳格に凍結されたプロトコルと実験の実施に委ねられる。

---

1. はじめに

大規模言語モデル（LLM）を外部検索やツールと組み合わせた情報探索システムでは、単一の生成経路に依存すると、回答がどの前提に依存しているのか、どの反例や適用除外条件が見落とされているのかを追跡しにくくなる。人間の調査業務では、仮説を立てた後に、その仮説が崩れる境界条件（反例、対象の不一致、情報の鮮度、一次情報源の信頼性）を意図的に洗い出し、焦点を絞った追加調査を行う。

本研究の作業仮説は、調査の途中で判明した未確認事項を契機に新たな探索課題を切り出し、異なる情報源から得た証拠を照合する機構が、最終判断の誤りを減らすというものである。この仮説は本稿の時点では検証していない。

本研究はこの仮説に対して「複眼型探索（Compound-eye Investigation）」という設計を提案する。名称は昆虫の複眼（個眼の集合体）に由来する。システムは自らの「理解状態」をデータとして保持し、現在の説明に対する未確認事項を解消するための探索役を立ち上げ、証拠を照合して状態を更新する。

1.1 操作的定義 (Operational Definitions)

本研究で用いる主要な概念の操作的定義は以下の通りである。

1. **理解状態 (Understanding State)**: モデルの内部思考や主観的意識ではなく、調査の目的（Goal）、現在の主張（Claims）、検証対象の仮説（Hypotheses）、取得済み証拠（Evidence）、未確認事項（Unverified Items）、および実施した検査履歴（Inspection History）を明示的に格納した外部構造化データ（External Structured Ledger）。
2. **探索役 (Investigator)**: 人格やキャラクター付け等の擬人化ペルソナではなく、特定の未確認事項、検証仮説、対象資料群、利用可能ツール、判定基準（支持/反証/不明）、および入出力・計算資源の上限が定義された、検証可能な具体的タスク仕様。
3. **未確認事項 (Unverified Item)**: 現在の主張の成立を左右する前提条件や反例候補のうち、直接の証拠による裏付けまたは反証が完了していない項目。
4. **証拠照合 (Evidence Reconciliation)**: 取得された証拠の出所（Provenance）、対象実体、調査時点、適用条件を照合し、同一本文の重複を排除した上で、説明できない対立を矛盾として保持する手続き。
5. **停止条件 (Stopping Condition)**: 必須の未確認事項が解決された場合、追加探索による状態変化が停止した場合（停滞）、総予算上限に到達した場合、または必要な調査能力が不足している場合に、未確認の理由を明記して探索を終了させる規則。

1.2 研究問い (Research Questions)

本研究では、研究計画 (PROTOCOL.md) に基づき、同一の基盤モデル（プロトコルで gemini-3.8-flash-high に固定）、初期資料群、ツール、および総予算の条件下で、以下の研究問い（RQ）を検証対象とする。各 RQ の主比較は 評価仕様 (EVALUATION_SPEC.md) §5.2 の対応表に従う。

- **主問い**: 同一資源予算の下で、理解状態から探索役を動的に構成する方式は、一般的な再点検、固定観点、および単独の適応探索と比較して、重要な証拠の発見率と最終判断の精度を改善するか。
- **RQ1 (動的観点選択の効果, H1)**: 調査途上の証拠と理解状態に応じて観点を選ぶ方式（条件E）は、事前に固定した観点（条件C）に比べて、結論を左右する必須事項の検出と最終判断の正答を増やすか。
- **RQ2 (探索役分割の効果, H2)**: 複数の探索役への分割（条件E）は、単一の適応探索（条件D）に比べて、重複しない情報源グループからの有効な証拠を増やすか。
- **RQ3 (証拠照合の効果, H3)**: 出所と適用条件を照合する機構（条件E）は、条件Dに比べて、誤った確認（偽警報）を減らし、かつ有効な証拠を過剰に棄却しないか。
- **RQ4 (状態更新の効果, H4)**: 探索結果を構造化データとして逐次反映する方式（条件E）は、一般的再点検（条件B）に比べて、反例を含むケースで初期の誤った結論を訂正できるか。

---

2. 関連研究 (Related Work)

本節は、Self-RAG、Adaptive-RAG、STORM、Reflexion の公式版（ICLR proceedings、ACL Anthology、NeurIPS proceedings）を照合した結果に基づく。各記述の後の角括弧は 検証台帳 の claim ID であり、台帳には該当箇所と原文の抜粋がある。「推論」と記した記述は、読んだ節に記載がないという本稿の読みであり、網羅的な不在の主張ではない。詳細は 関連研究台帳 に記録した。

2.1 自己点検型RAG: Self-RAG

Self-RAG（Asai et al., 2024）は、生成モデルの語彙に4種の反省トークン（Retrieve、IsRel、IsSup、IsUse）を加え、批評モデルがオフラインで付与したトークンを含むデータで生成モデルを学習する［selfrag-1, selfrag-2］。推論では1文を1セグメントとするビームサーチを行い、反省トークン確率の重み付き線形和で候補を選ぶ［selfrag-3, selfrag-4］。著者は、引用で十分に支持されない出力が残りうると述べている［selfrag-5］。

- **本提案との差**: Self-RAG は生成モデル（Llama2 7B/13B）の学習を前提とするため、重みを学習できないホスト型モデルにはそのまま適用できない（推論、selfrag-6）。反省トークンはセグメント単位の判定であり、論文の §3.1 から §3.3 には、タスク全体の主張や未確認事項を保持する外部記録の記述はない（推論、selfrag-7）。

2.2 適応型検索ルーティング: Adaptive-RAG

Adaptive-RAG（Jeong et al., 2024）は、解答を始める前に質問の複雑度を T5-Large の分類器で3段階に分け、非検索、単一段階検索、複数段階検索のいずれかを選ぶ［adaptiverag-1, adaptiverag-3］。複数段階戦略では、各段階の検索が先行文書と中間回答を含む文脈を入力に取るため、後段の検索は前段の結果に応じて変わる［adaptiverag-2］。分類器の学習ラベルは自動で作られ、著者は誤ラベルの可能性と、理想的な分類器との性能差を認めている［adaptiverag-4］。

- **本提案との差**: 戦略の選択は質問ごとに解答の前に行われ、複数段階戦略の中では検索が適応する。したがって Adaptive-RAG に動的な適応がないとは言えない。一方、取得した証拠の矛盾を契機に戦略を切り替える手順と、取得文書を一次出所でまとめる手順は記述されていない（推論、adaptiverag-5, adaptiverag-6）。Ommatidia は、調査途中に記録した未確認事項から次の探索役を作る点で設計が異なる。

2.3 多角観点対話による長文記事生成: STORM

STORM（Shao et al., 2024）は、関連トピックの Wikipedia 記事の目次から観点集合を生成し、各観点で執筆者役と検索に基づく専門家役が最大 M ラウンドの多ターン対話を行う［storm-1, storm-2, storm-3］。執筆者の追質問は対話履歴に応じて変わる［storm-3］。専門家役は検索結果を Wikipedia の指針に沿う規則ベースのフィルタにかけ、信頼できない情報源を除く［storm-4］。実装はゼロショットプロンプトであり、モデルの学習は行わない［storm-7］。著者は、収集情報が支配的な情報源に偏り、宣伝的な内容を含みうることを限界として挙げている［storm-5］。

- **本提案との差**: STORM の目的は解説記事の執筆であり、主張の成否判定ではない。観点集合は対話の前に決まり、各対話の中では追質問が適応する。規則ベースのフィルタは情報源の信頼性を対象とし、同じ原記事の転載をまとめる手順は記述されていない（推論、storm-6）。

2.4 言語的強化学習と反省記憶: Reflexion

Reflexion（Shinn et al., 2023）は、Actor、Evaluator、Self-Reflection の3モデルからなる。自己反省モデルは、評価器が出す二値またはスカラーの信号と軌跡から自然言語のフィードバックを作り、上限が通常1から3件のメモリに保存して次の試行へ渡す［reflexion-1, reflexion-2, reflexion-5］。モデルの重みは更新しない［reflexion-8］。実験の評価信号は、完全一致採点、事前定義のヒューリスティック、LLM による分類、自作の単体テストである［reflexion-4］。枠組み自体は、スカラー値と自由形式の言語のどちらのフィードバックも扱える［reflexion-3］。著者は、自己評価への依存、成功の形式的保証の欠如、局所最適の可能性を限界としている［reflexion-6］。

- **本提案との差**: Reflexion の反省は試行と試行の間に作られ、評価器の信号を契機とする。その信号は外部の正解に限らず、自作テストや LLM による判定も含む。Ommatidia は1回の試行の中で未確認事項の記録を更新する設計である。主張を証拠と出所に対応づける構造化記録は、論文に記述されていない（推論、reflexion-7）。

2.5 技術比較の整理とOmmatidiaの設計境界

下表は 2.1 から 2.4 の記述を整理したものである。「記述なし」は推論の行を指す。Ommatidia の列は PROTOCOL.md の設計であり、効果は検証していない。

比較項目	Self-RAG	Adaptive-RAG	STORM	Reflexion	Ommatidia（設計、未検証）
目的	検索・生成・自己批評を1モデルで行う	質問の複雑度に応じた検索戦略の選択	Wikipedia 型記事の事前調査と執筆	試行の繰り返しによる行動の改善	主張の成否を判定するための調査
状態の置き場所	生成文脈と反省トークン	検索文脈（文書と中間回答）	観点ごとの対話履歴と参照集合	反省文のメモリ（通常1から3件）	外部の理解状態

比較項目	Self-RAG	Adaptive-RAG	STORM	Reflexion	Ommatidia（設計、未検証）
観点や役割が決まる時点	単一モデル	質問ごと、解答の前	対話の開始前に観点集合を生成	3モデルの固定構成	調査途中の未確認事項から生成
途中での適応	セグメントごとの検索要否の判定	複数段階戦略の中で検索文脈を更新	対話内の追質問	試行間の言語的反省	理解状態の更新後に次の探索役を選ぶ
出所の扱い	IsSup による支持度の判定	記述なし	規則ベースの信頼性フィルタ。転載の集約は記述なし	記述なし	本文ハッシュによる同一文の重複排除と範囲照合
学習の要否	生成モデルと批評モデルを学習	分類器（T5-Large）を学習	学習なし	重みの更新なし	学習なし

本提案は、LLM が自律的に新しい概念を獲得するといった主張をしない。本提案は、外部化した理解状態を中心に、現在の主張を反証または限定するための探索役を割り当て、同一本文の重複を除いて証拠を照合し、複合予算内で停止するというシステム設計である。上表の差は設計上の差である。この組み合わせが先行研究にないこと、およびこの設計に効果があることは、本稿では主張しない。

---

3. 提案手法: Ommatidia

Ommatidia は、外部化された「理解状態」の管理部、探索役の「動的構成部」、取得証拠の「照合部」、および「状態更新・停止判定部」から構成される。

3.1 理解状態のデータ構造 (Understanding State)

理解状態 S は、モデルの内部表現に依存しない、外部の検証可能なデータ構造として定義される。

S = 〈 G, C, H, E, U, I 〉

- G (Goals): 調査の目的および解決すべき中心課題。
- C (Claims): 現在導出されている主張の集合。各主張には確信の度合いではなく、根拠となる証拠の参照が紐付く。
- H (Hypotheses): 主張を検証、限定、または反証するために立てられた作業仮説。
- E (Evidence Ledger): 取得された証拠の台帳。各証拠は本文抜粋、情報源の所在、取得日時、対象実体、適用条件、出所種別、本文の SHA-256 ハッシュを持つ。
- U (Unverified Items): 主張の妥当性を左右する未確認事項の集合。各項目は「生じた具体的なきっかけ」と「目的への影響理由」を伴う。
- I (Inspection History): 実行された検査と探索役の履歴（投入プロンプト、使用ツール、消費資源）。

主張の状態は、プロトコルの用語に合わせて「未確認（unverified）」「支持（supported）」「反証（contradicted）」「対立（disputed）」の4状態に区別する。最終判定はこれに「判定不能（inconclusive）」を加えた4値（supported、contradicted、disputed、inconclusive）のいずれかとする。検索結果が得られなかったことやツールが使えなかったことを、「反証」や「解決」に読み替えることは禁止する。

3.2 探索役の動的生成 (Dynamic Investigator Dispatch)

探索役は擬人化されたペルソナではなく、明示的な検査仕様として生成される。現在の理解状態 S に含まれる未確認事項 $u \in U$ に対し、以下の属性を持つ探索役 r_u を定義する。

1. **対象未確認事項**: 検証すべき具体的な疑問点。
2. **検証仮説**: 主張が成立しない条件、または成立するための前提。
3. **対象資料群とツール**: 検索キーワード、参照すべき文書群、許可されたツール（検索、ファイル閲覧等）。

4. **判定条件**:「支持」「反証」「不明」を切り分ける具体的基準。
5. **資源上限**: 探索役に割り当てられる最大呼び出し回数、最大入力文字数、タイムアウト。

単一の探索役で足りる場合は、複数の探索役を立ち上げない。並行して動作する探索役は最大3とし、総予算の範囲を超えて実行しない。

3.3 証拠の照合と出所依存関係の解決 (Evidence Reconciliation)

探索役から証拠が報告されたとき、検索順位や表面的な文言の一致だけで正当性を判断しない。以下の照合手続きを適用する。

- **同一本文の重複排除**: 本文の SHA-256 ハッシュが一致する抜粋は、複数の探索役が取得しても1件の証拠として数える。同じ一次情報源の転載を言い換えまで含めて1件にまとめることは設計上の目標であるが、プロトコルが定める手順は同一本文の重複排除に限られる（§7 の限界5）。
- **条件と時期の整合性**: 証拠が成立する前提条件、調査対象のバージョン、発表時期を照合し、現在の主張と範囲が合っているかを確認する。
- **対立の明示保持**: 信頼できる情報源どうしが矛盾する場合、一方を採用して解決とみなさず、「対立（disputed）」として理解状態に保持する。

3.4 状態更新と停止規則 (State Update & Stopping Rules)

探索役の実行結果に基づいて理解状態 S を更新する。探索は、以下のいずれかの条件が満たされたときに停止する。

1. **必須事項の解消**: 調査目的に不可欠な未確認事項がすべて検証（支持または反証）された場合。
2. **証拠・状態の停滞 (Stagnation)**: 新たな探索を行っても新規証拠が得られず、理解状態が変化しなくなった場合。
3. **予算の枯渇 (Budget Exhaustion)**: モデル呼び出し回数、ツール呼び出し回数、入力文字数、出力トークン数、または経過時間のいずれかが上限に達した場合。
4. **能力の不足**: 必要な検証ツールが使えないなど、これ以上の調査が構造的に不可能な場合。

探索が終了したとき、未解決のまま残った未確認事項とその理由（予算上限、情報源の不在など）を必ず最終出力に記録する。

---

4. 実験計画 (Experimental Protocol)

本計画は PROTOCOL.md と EVALUATION_SPEC.md に従う。評価用データへの適合を防ぐため、評価データを見る前に設定と正解規則を固定する。

4.1 比較条件

同一の基盤モデル、同一のツール環境、同一の総資源予算上限の下で、以下の5条件を比較する。

- **条件A (通常探索 / Baseline Exploration)**: 単一エージェントがタスク資料と初期回答案を受け取り、ツールを使って誘導なしに調査し、結論を出すか予算を使い切るまで続ける。
- **条件B (一般的再点検 / General Re-inspection)**: 1試行の中で2段階を実行する。第1段階は条件Aと同じ探索プロンプトで初期評価を作る。第2段階では、見落とした反例、情報源の新しさ、対象の混同や範囲外への拡大を再点検させる汎用プロンプトを与える。両段階は同じ1試行の予算を共有する。条件Bは汎用の再点検プロンプトであり、Reflexion や Self-RAG の再実装ではない。
- **条件C (固定観点 / Fixed Viewpoints)**: 全ケースで同じ5つの固定観点を調べる。観点は、適用範囲、反例と否定的事例、時期と版の相違、依存関係の不変条件、出所の重複と循環引用である。

- **条件D (単独適応探索 / Single Adaptive Exploration)**: 明示的な理解状態を保持し、単一の探索役が未確認事項を1件ずつ選んで検査し、状態を更新する。
- **条件E (Ommatidia)**: 理解状態から観点と優先すべき未確認事項を導き、最大3の探索役を並行に実行し、取得証拠を照合して状態を更新する。

主比較は EVALUATION_SPEC.md §5.2 に従い、H1 を E と C、H2 と H3 を E と D、H4 を E と B で比較する。

4.2 資源予算の上限 (Budget Constraints)

全条件に、1試行あたり同一の予算上限を適用する。計画生成、探索役の呼び出し、通信、状態の記録、JSON 修復の再試行、最終統合に要する消費量はすべて同じ予算に計上する。

- モデル呼び出し回数: 最大8回
- 外部ツール呼び出し回数: 最大12回
- 入力文脈: 最大48,000文字（送信前に文字数で検査する）
- 出力トークン数: 最大16,000トークン（1回あたり4,000トークン）
- 経過時間: 最大180秒
- 同時実行探索役数: 最大3（条件Eのみ）

実行環境が直接測れるのは、経過時間（ミリ秒）、モデル呼び出し回数、ツール実行回数、入力文字数、再試行とスキーマ誤りの回数である。API が使用量を返さない場合のトークン数と、金額としての費用は測定できない。基盤モデルの費用（cost.output）は実行環境で null と報告されるため、費用の比較は行わず、効率は上記の物理量で報告する。

4.3 評価ケースと実行規模

評価ケースは、ソフトウェア開発、業務自動化、資料調査の3領域から各16件、計48件の合成ケースで構成する。各領域の16件を、開発・調整用（Development Set）8件と、結果確定まで非公開とする評価用（Held-out Evaluation Set）8件に分ける。したがって開発用は24件、評価用は24件である。ケースには、隠された重要資料、資料の時期の相違、異なる対象実体、転載による重複情報、反例、追加確認が不要なケース、結果が得られないケース、ツールが使えないケースを含める。正解側の必須確認事項と証拠の適用範囲は事前に定義し、モデルには渡さない。

計画上の実行規模は以下の通りである。各ケース・各条件の試行は1回（R = 1）とする。

段階	対象	ケース数	条件数	試行数	モデル呼び出し上限	ツール呼び出し上限
第1段階: 開発パイロット	開発用	24	5	120	960	1,440
第2段階: 事前登録済み評価	評価用	24	5	120	960	1,440
合計		48	5	240	1,920	2,880

モデル呼び出し上限は、1試行あたり8回（計画・探索役・通信・再試行・統合を含む）に試行数を掛けた値である。評価用24件で3回ずつ試行する拡張（360試行）はプロトコル上の任意項目であり、別途の承認を要する。この拡張は承認されておらず、本計画に含めず、実行していない。

評価用の指標は評価用24件だけを分母とし（$N_{heldout} = 24$）、開発用のケースを分母に混ぜない。評価用ケースの正解、必須証拠の所在、採点規則は、実行前に SHA-256 で封印する。プロンプト、閾値、発見的規則は開発用24件だけで固定してから評価用の実行に進む。

現時点の状態は次の通りである。作業記録（research/hand_over_dev_cases.md）によれば、開発用24件は8種類のケース型 × 3件として作成済みである。評価用24件は正式版として承認されておらず、本稿の実行には用いない。封印記録（research/seal_manifest.json）には、開発用 manifest（research/datasets/dev/manifest.json）と評価用 manifest（research/datasets/heldout/manifest.json）の項目がある。評価用 manifest の実ファイルは、未追跡の作

業コピーとして管理する。実行時の凍結（research/runtime_freeze_r4.json）は存在するが、評価パッケージの状態は blocked_rebuild_required であり、実験試行はまだ実行されていない（studyTrialsExecuted = 0）。したがって、本稿には実験結果を含めない。

4.4 評価指標 (Metrics)

指標の定義は EVALUATION_SPEC.md §2 に従う。最終判定は supported、contradicted、disputed、inconclusive の4値で採点する。

主指標:

1. **最終判断正答率** (FDA): 最終判定が正解の判定と一致したケースの割合。分母は $N_{heldout} = 24$。
2. **必須証拠再現率** ($Recall_{crit}$): 各ケースで正解側が定めた必須証拠のうち、正しく取得し引用した割合のケース平均。

副指標:

1. **偽警報率** (FAR): 生成した確認のうち、存在しない矛盾や範囲外の問題を対象としたものの割合。
2. **確認候補の適合率** ($Prec_{cand}$): 生成した未確認事項のうち、実在する証拠上の欠落に対応したものの割合。
3. **判断悪化率** (DDR): 初期回答案が正しかったケースのうち、最終判定が誤りに変わった割合。
4. **正当な保留率と不当な保留率** (WAR, UAR): 解決不能なケースで inconclusive と答えた割合と、解決可能なケースで inconclusive と答えた割合。
5. **独立情報源数** (DSC): 取得し検証した、重複しない情報源グループの数。
6. **効率**: ツール呼び出し1回あたり、および経過時間1秒あたりの必須証拠取得数。

4.5 統計解析と評価者のマスキング

解析の単位はケースである。R = 1 のため、同じケース内の反復による集落化は生じない。条件間の比較は、同じケースの対で行う。

- **二値の主要評価項目（H1、H4）**: 各ケースで各条件が1つの二値結果（最終判定が正しいか否か）を持ち、ケースで対になることを前提に、両側の正確 McNemar 検定を用いる。検定は不一致の対だけに依存する。H4 は反例を含むケースの部分集合で比較し、その件数は評価用24件のうち12件に固定する。この件数と対象ケースの指定は、評価用ケースの作成時に定め、実行前に封印する。Holm 補正後の有意水準 0.0125 で有意となるには、一方向の不一致が少なくとも8対必要である。
- **連続値・計数の主要評価項目（H2 の** DSC**、H3 の** FAR）: EVALUATION_SPEC.md に従い、ケース単位の対応のある Wilcoxon 符号付順位検定を用いる。差が0の対は除外する。同順位には平均順位を与え、連続性補正のない正規近似を用いる。非零の対が6組未満の場合は検定不能として不決定（inconclusive）とする。
- **割合の不確かさ**: 各条件の FDA には、連続修正付きの Wilson スコア 95% 信頼区間を付ける。
- **多重性**: 4つの主要仮説の検定に Holm 法を適用し、族全体の第1種の過誤を 0.05 に抑える。
- **副次解析**: 連続値の差（Δ $Recall_{crit}$ など）の BCa ブートストラップ 95% 信頼区間（B = 10,000）は探索的な指標として扱う。

$N_{heldout} = 24$ では検出力が限られる。両側の正確 McNemar 検定で $p \le 0.05$ となるには、不一致の対がすべて同じ向きでも6対以上が必要である（$p = 0.03125$）。Holm 法の最初の閾値 0.0125 を下回るには8対以上が必要である（$p \approx 0.0078$）。この値は二項分布から計算した設計上の性質であり、実験結果ではない。有意差が出ないことは、差がないことの根拠にならない。

評価のマスキングは評価者側に限る。エージェントは条件ごとのプロンプトを実行指示として受け取るため、自らの条件を知っている。採点スクリプトと人間の評価者は、条件ラベルを除き無作為な ID を付けた出力を受け取り、対応表は指標の計算後にだけ照合する。したがって本計画は単盲検（評価者マスキング）であり、二重盲検ではない。採

点は封印済みの正解との JSON 項目の比較とハッシュ照合で自動的に行い、正解をモデルや評価用プロンプトに渡さない。

---

5. 実験結果 (Results)

状態: 実験未実施（Pending）

本研究は現在、設計と実験プロトコルの固定段階にある。実モデルによる比較試行は0件であり、計画された240試行はいずれも実行していない。費用とトークン消費量は未測定である。いかなる測定値、成功率、費用の見積もりも、実際の実行結果が得られるまで本文に記載しない。

リポジトリには以下の成果物があるが、いずれも RQ に対する実験結果ではない。

- **開発用ケースの形式検査**: 作業記録の検査は、正解の判定をそのまま状態に設定して採点器に通し、24件すべてで「100%」の成功を確認したものである。これはケースの形式と採点器の整合を確かめる検査であり、いずれの条件の有効性も示さない。
- **機構の模擬実行**: research/output/paired_E_vs_D_run_paired_001.json は、2件の模擬タスク（モデル指定は null）で条件EとDを流した実行基盤の動作確認であり、差の平均は 0.0 である。n = 2 の模擬実行であり、実証研究の結果ではない。
- **文書監査**: research/tombo-audit/ は、プロトコルと文書の整合を点検した記録であり、比較実験ではない。

---

6. 考察 (Discussion)

実験の実施後に検証する主な考察項目は以下の通りである。

1. **動的観点選択の情報利得とオーバーヘッド**: 観点を動的に生成することが、固定観点や一般的再点検より多くの必須証拠の検出につながるか、それとも呼び出し回数と遅延を増やすだけに終わるか。
2. **探索役分割における協調コスト**: 探索役を並行に動かした場合、同一資料の重複取得や文脈の断片化がどの程度起こり、照合部がそれを集約できるか。
3. **証拠照合による過剰棄却のリスク**: 出所と適用条件の照合が、必要な補助的証拠まで除いて判断不能を増やしていないか。
4. **合成環境から実務への一般化限界**: 評価用24件の合成ケースで得られる傾向が、情報源が不透明な実際のウェブ調査にどこまで当てはまるか。

---

7. 限界 (Limitations)

本提案および評価計画には、以下の限界がある。

1. **未確認事項生成のLLM依存性**: システムが挙げる未確認事項は、基盤モデルの知識とプロンプトによる推論に依存する。モデルが認識できない盲点を、外部情報なしに発見できる保証はない。
2. **形式検証の非保証**: 証拠の照合と状態遷移の管理は発見的な手続きであり、形式検証や事実性の証明を提供しない。
3. **外部ツールの品質依存**: 探索役の調査精度は、利用できる外部ツール（検索の網羅性、取得の精度など）の制約を直接受ける。
4. **状態管理に伴うオーバーヘッド**: 理解状態の維持と出所の照合は、直接生成する方式に比べて呼び出し回数、入力文字数、遅延を増やす。この増加分は、すべての条件で同じ予算に計上する。

5. **同一本文ハッシュの限界**: プロトコルが定める重複排除は SHA-256 が一致する同一の文しか検出しない。言い換えを伴う転載は独立した証拠として数えられうる。
6. **統計的検出力**: 評価用は24件であり、§4.5 の通り、正確 McNemar 検定で有意となるには一方向に偏った不一致の対が6対以上（Holm 法の最初の閾値では8対以上）必要である。小さな差は検出できない可能性が高い。
7. **盲検化の範囲**: 条件を知らずに済むのは評価者と採点スクリプトだけであり、エージェントは自らの条件を知っている。
8. **ケース作成者と被評価モデルの重なり**: 作業記録によれば、開発用24件は基盤モデルと同じ gemini-3.8-flash-high が作成した。ケースの表現が被評価モデルに有利または不利に偏る可能性がある（推論）。評価用ケースの作成者は未定である。
9. **単一の基盤モデル**: 結果が得られても、それはプロトコルで固定した1つの基盤モデルについての結果であり、他のモデルへの一般化は検証しない。
10. **未実施の実験による経験的証拠の保留**: 本稿の設計と仮説は、実際の測定データで裏付けられるまでは提案の段階にとどまる。

---

8. 結論 (Conclusion)

本稿では、AI エージェントによる調査において、自らの理解状態を外部データとして保持し、未確認事項に基づいて探索役を構成して証拠を照合するシステム「Ommatidia」の設計と実験計画を示した。Self-RAG、Adaptive-RAG、STORM、Reflexion の公式版を照合し、機構の差を、論文に記述された内容と本稿の推論とに分けて整理した。この整理は設計上の差を示すものであり、新規性や効果を示すものではない。

今後の課題は、評価用24件のケースを作成して封印し、開発用120試行で設定を固定した後、評価用120試行を実行することである。その上で、独立した検証者による確認を経て、提案手法の有効性と限界を報告する。

参考文献 (References)

1. Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil, and Hannaneh Hajishirzi. 2024. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. In International Conference on Learning Representations (ICLR 2024), pages 9112–9141. arXiv:2310.11511.
2. Soyeong Jeong, Jinheon Baek, Sukmin Cho, Sung Ju Hwang, and Jong C. Park. 2024. Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity. In Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers), pages 7036–7050. arXiv:2403.14403.
3. Yijia Shao, Yucheng Jiang, Theodore A. Kanell, Peter Xu, Omar Khattab, and Monica S. Lam. 2024. Assisting in Writing Wikipedia-like Articles From Scratch with Large Language Models. In Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers), pages 6252–6278. arXiv:2402.14207.
4. Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. 2023. Reflexion: Language Agents with Verbal Reinforcement Learning. In Advances in Neural Information Processing Systems 36 (NeurIPS 2023), pages 8634–8652. arXiv:2303.11366. (arXiv の現行版は Edward Berman を加えた6名を著者として挙げる。)